Punto_Flotante

April 7, 2022

0.0.1 Repaso de representación de número flotante

[1]: using Plots

Recordemos que los números flotantes tienen la forma:

$$x = (-1)^s * 0.a_1 a_2 a_3 \dots a_t * \beta^e = (-1)^s * m * \beta^e, \qquad \frac{1}{\beta} < m < 1$$

Donde el primer elemento, a_1 es no nulo (distinto de cero). En el caso de la representación binaria, $\beta=2$, tendremos que necesariamente $a_1=1$ y por lo tanto no lo incluiremos.

0.1 Ejemplo de representación de número en punto flotante simple (Float32)

Consideremos el número: x = -118.625

Su representación binaria es: x bin = -1110110.101

Lo chequeamos:

[2]: -118.625

Para pasarlo a la representación de punto flotante 32, primero corremos la coma hasta el primer lugar no nulo de la izquierda (7 lugares):

$$x_{bin} = (-1)^1 * (0.1110110101) * 2^7 \\$$

Como 7 en binario es: 111 Pero debemos usar la representación sesgada y por lo tanto ir a E=126+7=133 que se representa como: 10000101

[3]: 7

[4]: 133

Como el primer elemento de la mantiza debe ser necesariamente no nulo debe ser un 1, que se omite. La representación será:

 $x_float32 = 1_10000101_110110101000$

 $[5]: fl_x = Float32(-118.625)$

[5]: -118.625f0

[6]: bitstring(fl_x)

[6]: "110000101110110101000000000000000"

0.1.1 Ejemplo con F(2,3,-1,2)

 $\beta=2,\,t=3,\,L=-1$ y U=2 (sesgado por dos unidades, E=e+L+1)

Listemos primero los **normalizados** (los positivos solamente):

$$(0.100)_2 \times 2^{-1} = \frac{1}{4}, \quad (0.101)_2 \times 2^{-1} = \frac{5}{16}, \quad (0.110)_2 \times 2^{-1} = \frac{3}{8}, \quad (0.111)_2 \times 2^{-1} = \frac{7}{16},$$

$$(0.100)_2 \times 2^0 = \frac{1}{2}, \qquad (0.101)_2 \times 2^0 = \frac{5}{8}, \qquad (0.110)_2 \times 2^0 = \frac{3}{4}, \qquad (0.111)_2 \times 2^0 = \frac{7}{8},$$

$$(0.100)_2 \times 2^1 = 1$$
 $(0.101)_2 \times 2^1 = \frac{5}{4}$, $(0.110)_2 \times 2^1 = \frac{3}{2}$, $(0.111)_2 \times 2^1 = \frac{7}{4}$

$$(0.100)_2 \times 2^2 = 2,$$
 $(0.101)_2 \times 2^2 = \frac{5}{2},$ $(0.110)_2 \times 2^2 = 3,$ $(0.111)_2 \times 2^2 = \frac{7}{2}.$

```
[7]: L = -1
U = 2
= 2.

for j in 0:(-1)
    for k in 0:(-1)
        for e in L:U
            println((^(-1) + j*^(-2) + k*^(-3))*^e)
        end
    end
end
```

0.25

0.5

1.0

2.0

0.3125

0.625

1.25

2.5

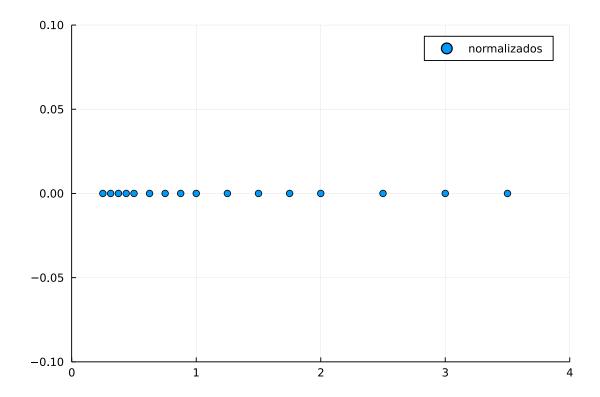
0.375

0.75

```
3.0
     0.4375
     0.875
     1.75
     3.5
     Ahora los ordenamos para graficarlos:
 [8]: x_fln = zeros(2*2*4) # 16 lugares
      for j in 0:(-1)
          for k in 0:(-1)
              for e in L:U
                  x_{fln}[Int(1+ 2*j+ k +4*(e-L))] = (^(-1) + j*^(-2) + k*^(-3))*^e
              end
          end
      end
 [9]: x_fln
 [9]: 16-element Vector{Float64}:
       0.25
       0.3125
       0.375
       0.4375
       0.5
       0.625
       0.75
       0.875
       1.0
       1.25
       1.5
       1.75
       2.0
       2.5
       3.0
       3.5
[10]: cero(x) = 0.0
      scatter(x_fln,cero.(x_fln), xlim=(-0.001,4.0), ylim=(-0.1,0.1),_{u}
       ⇔label="normalizados")
```

1.5

[10]:



0.2 Números especiales

Dada una representación $\mathcal{F}(\beta, t, L, U)$

Además de los números ya incluidos las representaciones modernas (IEEE754) agregan varios más:

- 1. El cero: mantiza 0 y e = (L-1)
- 2. Números denormalizados (a_1) puede ser cero) y e = (L-1). Cubren la región cercana a zero.
- 3. Inf y -Inf resultados de dividir por cero o de overflow (positivo y negativo) mantiza nula y e $=\mathrm{U}{+}1$
- 4. NaN que son resultados ilegales, como por ejemplo 0/0

$$(\pm \texttt{Infinity}\) + (+1) = \pm \texttt{Infinity}$$

$$(\pm \texttt{Infinity}\) \cdot (-1) = \mp \texttt{Infinity}$$

$$(\pm \texttt{Infinity}\) + (\pm \texttt{Infinity}\) = \pm \texttt{Infinity}$$

$$(\pm \texttt{Infinity}\) + (\mp \texttt{Infinity}\) = \texttt{NaN}$$

$$1/(\pm 0) = \pm \texttt{Infinity} \qquad 1/(\pm \texttt{Infinity}\) = \pm 0$$

$$0/0 = \texttt{NaN} \qquad (\pm \texttt{Infinity}\)/(\pm \texttt{Infinity}\) = \texttt{NaN}$$

$$0 \cdot (\pm \texttt{Infinity}\) = \texttt{NaN}$$

Valor	Exponente	Mantisa
normalizados	$L \le e \le U$	$\neq 0$
denormalizados	L-1	$\neq 0$
± 0	L-1	0
$\pm { t Infinity}$	U+1	0
NaN	U+1	$\neq 0$

[11]: 1/0

[11]: Inf

[12]: bitstring(Inf)

Ahora veamos cuales son los **desnormalizados** de la representación $\mathcal{F}(2,3,-1,2)$:

$$0.001 \times 2^{-1} = \frac{1}{16}, \quad 0.010 \times 2^{-1} = \frac{1}{8}, \quad 0.011 \times 2^{-1} = \frac{3}{16}.$$

```
end
      end
[14]: x_fld
[14]: 4-element Vector{Float64}:
       0.0
       0.0625
       0.125
       0.1875
[15]: 3/16
[15]: 0.1875
[16]: scatter(x_fln,cero.(x_fln), xlim=(-0.001,4.0), ylim=(-0.1,0.1),__
       ⇔label="normalizados")
      scatter!(x_fld,cero.(x_fld).+0.05, label="desnormalizados")
[16]:
            0.10
                                                                    normalizados
                                                                    desnormalizados
            0.05
            0.00
           -0.05
```

3

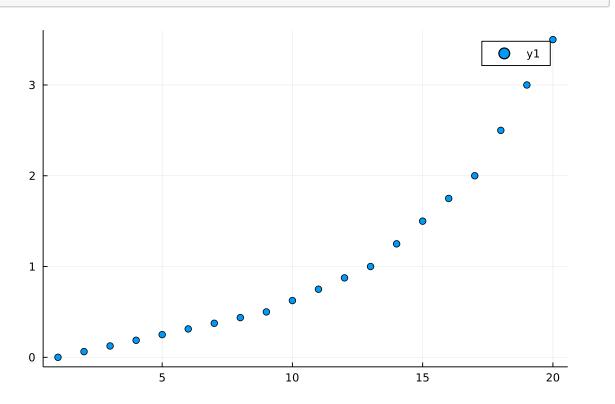
-0.10



Figura 4. Números de punto flotante, incluyendo los denormalizados, del conjunto $\mathbb{F}(2,3,-1,2).$

[17]: scatter([x_fld;x_fln])

[17]:



0.2.1 Los ceros

[18]: bitstring(0.0)

Hay por lo tanto dos ceros....

[19]: bitstring(-0.0)

[20]: 1/(-0.)

[20]: -Inf

0.2.2 Distancia entre números consecutivos:

La distancia entre dos números consecutivos en el intervalo $x \in [\beta^e, \beta^{e+1})$:

$$\epsilon(x) = \frac{1}{\beta^t} * \beta^{e+1} = \beta^{e-t+1}$$

La distancia al número más cercano a 1 (POR ARRIBA) es $\epsilon(1) = \beta^{1-t}$ (ya que $1 = 0.1\beta^1$)

La distancia a un número se denomina ϵ y depende de la representación que la máquina y el software haga de los números.

En Julia (en FORTRAN también) hay una función que nos devuelve el valor de esta distancia para cada número que le demos:

[21]: ?eps()

[21]:
 eps(::Type{T}) where T<:AbstractFloat
 eps()</pre>

Return the *machine epsilon* of the floating point type T (T = Float64 by default). This is defined as the gap between 1 and the next largest value representable by typeof(one(T)), and is equivalent to eps(one(T)). (Since eps(T) is a bound on the *relative error* of T, it is a "dimensionless" quantity like one.)

1 Examples

eps(x::AbstractFloat)

Return the *unit in last place* (ulp) of x. This is the distance between consecutive representable floating point values at x. In most cases, if the distance on either side of x is different, then the larger of the two is taken, that is

```
eps(x) == max(x-prevfloat(x), nextfloat(x)-x)
```

The exceptions to this rule are the smallest and largest finite values (e.g. nextfloat(-Inf) and prevfloat(Inf) for Float64), which round to the smaller of the values.

The rationale for this behavior is that eps bounds the floating point rounding error. Under the default RoundNearest rounding mode, if y is a real number and x is the nearest floating point number to y, then

$$|y - x| \le \operatorname{eps}(x)/2.$$

See also: nextfloat, issubnormal, floatmax.

2 Examples

```
julia> eps(1.0)
2.220446049250313e-16

julia> eps(prevfloat(2.0))
2.220446049250313e-16

julia> eps(2.0)
4.440892098500626e-16

julia> x = prevfloat(Inf)  # largest finite Float64
1.7976931348623157e308

julia> x + eps(x)/2  # rounds up
Inf

julia> x + prevfloat(eps(x)/2) # rounds down
1.7976931348623157e308
```

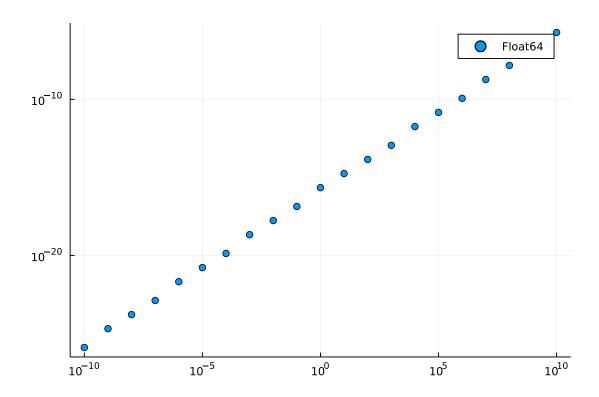
```
eps(::Type{DateTime}) -> Millisecond
eps(::Type{Date}) -> Day
eps(::Type{Time}) -> Nanosecond
eps(::TimeType) -> Period
```

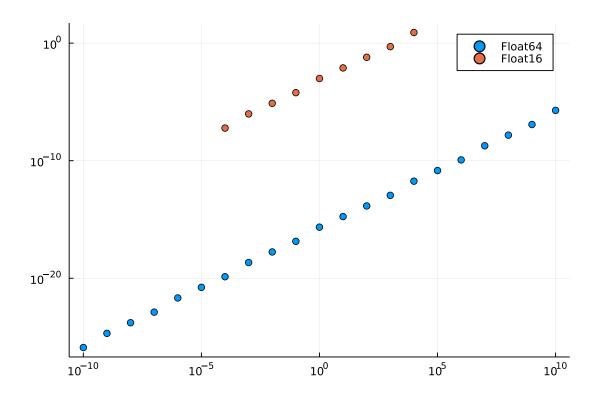
Return the smallest unit value supported by the TimeType.

3 Examples

```
julia> eps(DateTime)
1 millisecond
julia> eps(Date)
1 day
```

```
julia> eps(Time)
     1 nanosecond
[22]: eps(1.)
[22]: 2.220446049250313e-16
[23]: bitstring(eps(0.))
[24]: 1. + eps(1.)*0.5 == 1.
[24]: true
[25]: 1. + eps(1.)*0.6
[25]: 1.0000000000000000
[26]: eps(10.)
[26]: 1.7763568394002505e-15
[27]: 10. + eps(1.) == 10.
[27]: true
     Veamos en un gráfico como crece la distancia entre números consecutivos:
[28]: x = [10.0^{\circ}i \text{ for } i -10:10];
[29]: scatter(x,eps.(x),yscale=:log10, xscale=:log10, label="Float64")
[29]:
```





3.1 Los límites de la representación:

El número finito más grande que podemos representar en Float64 es:

- [33]: prevfloat(Inf)
- [33]: 1.7976931348623157e308

El más pequeño (en módulo):

- [34]: nextfloat(0.)
- [34]: 5.0e-324

El primer número cercano a zero es un número denormalizado.

- [35]: bitstring(eps(0.0))
- [36]: bitstring(eps(Float32(0.0)))